Curso Ciencia de Datos

Proyecto Módulo 7

Segmentador Inteligente de Clientes Minoristas

Alumno Reinaldo Elgueta Ábalos
Abril 2026

Lección 1: Fundamentos del Aprendizaje No Supervisado

📍 Tareas a desarrollar:

1. Principales tareas que resuelve el aprendizaje no supervisado

El aprendizaje no supervisado se enfrenta a datos que no tienen etiquetas ni respuestas predefinidas.

Sus tareas principales son:

- Descubrimiento de estructuras: Identificar cómo se agrupan los datos de forma natural sin intervención humana.
- Simplificación de datos: Comprimir la información eliminando variables redundantes o ruido, manteniendo lo esencial.
- Detección de patrones anómalos: Encontrar registros que no encajan con el comportamiento general del conjunto de datos.

2. Clasificación de técnicas por tipo

Para el proyecto de Retail Insights S.A., clasificamos las técnicas de la siguiente manera:

Tipo de Técnica	Descripción	Algoritmos Clave
Clusterización (Agrupamiento)	Divide los datos en grupos (clústeres) basados en similitudes. Los elementos dentro de un grupo son muy parecidos entre sí, pero diferentes a los de otros grupos.	K-Means, Clústerización Jerárquica, DBSCAN.
Reducción de Dimensionalidad	Reduce el número de variables de entrada para simplificar el modelo o permitir su visualización en 2D o 3D.	PCA (Principal Component Analysis), t-SNE.
Asociación	Identifica reglas que rigen la relación entre variables (ej. "quien compra X, suele comprar Y").	Apriori, Eclat.

3. Análisis de casos reales de aplicación

El aprendizaje no supervisado es un estándar industrial en diversos sectores:

- Retail (Nuestro caso): Segmentación de clientes según hábitos de compra para personalizar promociones de marketing.
- Ciberseguridad: Detección de intrusiones o fraudes mediante la identificación de patrones de red que se desvían de lo normal.
- Biología: Clasificación de secuencias de ADN o especies animales basadas en rasgos compartidos cuando no se conoce la taxonomía previa.

Lección 2: Técnicas de Clusterización

📍 **Tareas a desarrollar:**

● **Definir escenarios donde se aplique clusterización**

Escenarios de Aplicación de Clusterización

La clusterización es ideal cuando no conocemos las categorías de antemano.
Escenarios clave:

- Segmentación de Clientes: Agrupar por hábitos de gasto e ingresos (nuestro proyecto).
- Bioinformática: Agrupación de genes con patrones de expresión similares.
- Detección de Fraude: Identificar grupos de transacciones que se desvían del comportamiento normal (anomalías).

● **Explicar ventajas y desventajas de la técnica**

Ventajas	Desventajas
Descubrimiento: Revela patrones que los analistas no habían notado.	Subjetividad: No hay una "respuesta correcta"; la interpretación depende del analista.
Flexibilidad: Se adapta a datos sin etiquetas de cualquier industria.	Sensibilidad: Muchos algoritmos fallan ante *outliers* o ruido en los datos.

Escalabilidad: Permite procesar miles de clientes rápidamente.	Selección de K: Determinar el número de grupos óptimo puede ser complejo.

- **Comparar K-Means, DBSCAN y agrupamiento jerárquico teóricamente**

Algoritmo	Enfoque Principal	¿Requiere definir K?	Fortalezas
K-Means	Basado en Centroides (promedios).	Sí	Es extremadamente rápido y eficiente para grupos esféricos y bien definidos.
Hierarchical	Basado en Conectividad (jerarquías).	No (se elige en el dendrograma)	Permite visualizar la relación entre grupos (árbol). No asume una forma específica.
DBSCAN	Basado en Densidad.	No	Identifica clústeres de cualquier forma y es el mejor detectando ruido/outliers.

● **Asociar cada algoritmo a un tipo de dato o problema real**

K-Means → Retail Estándar: Ideal para segmentar clientes en grupos claros como "Ahorradores", "Lujo" y "Promedio", donde los datos suelen agruparse de forma compacta.

Agrupamiento Jerárquico → Taxonomía: Útil en estudios de mercado donde queremos ver subgrupos dentro de grupos (ej: dentro de "Jóvenes", separar "Estudiantes" de "Primer empleo").

DBSCAN → Análisis Geográfico: Excelente para identificar zonas de alta densidad de entregas en una ciudad e ignorar direcciones erróneas o puntos aislados (ruido).

Lección 3: Reducción Dimensional y Preprocesamiento

Tareas a desarrollar:

● **Preparar un dataset de alta dimensión.**

Antes de reducir dimensiones, debemos asegurar que los datos sean comparables.

Limpieza: Manejo de valores nulos y eliminación de outliers que puedan sesgar los clústeres.

Escalado (Normalización/Estandarización): Dado que PCA (Principal Component Analysis) es sensible a las variaciones de escala, se debe usar las herramientas de procesamiento de datos StandardScaler o MinMaxScaler de Scikit-Learn. Ya que permitirán escalar las características numéricas de un dataset antes de entrenar modelos de ML.

● **Implementar PCA y t-SNE con scikit-learn**

Implementar PCA

El objetivo de PCA es transformar las variables originales en un nuevo conjunto de variables (componentes principales) que retengan la mayor varianza posible.

Tarea: Reducir el dataset a 2 o 3 componentes principales para poder graficarlos.

Análisis: Revisar la "varianza explicada" para saber cuánta información se perdió en la reducción.

Cuando se aplica PCA (Análisis de Componentes Principales), se están comprimiendo muchas variables en unas pocas "componentes". Al hacer esto, es inevitable perder algo de detalle. La “varianza explicada” mide qué tan buena es esa compresión.

Implementar t-SNE

A diferencia de PCA (que es lineal), t-SNE es una técnica no lineal excelente para detectar estructuras locales y grupos en datos de alta dimensión.

Tarea: Ejecutar t-SNE y comparar visualmente si los grupos se ven más definidos que con PCA

● **Justificar cuál técnica conviene para el problema actual**

¿Por qué utilizamos PCA (Principal Component Analysis)?

- Eficiencia Lineal:

  PCA es ideal para reducir la complejidad del dataset manteniendo la estructura global de los datos. Al transformar las variables originales en componentes principales, podemos eliminar el "ruido" y quedarnos con las dimensiones que realmente capturan las diferencias entre clientes.

- Preparación para Clusterización:

  Algoritmos como K-Means funcionan mejor en espacios de menor dimensión donde las variables no están correlacionadas. PCA nos entrega precisamente eso: componentes ortogonales (independientes).

- Métrica de Control:

  Nos permite calcular la varianza explicada, dándonos una medida objetiva de cuánta información estamos reteniendo (por ejemplo, un 80% de los patrones de compra originales).

¿Por qué utilizamos t-SNE (t-distributed Stochastic Neighbor Embedding)?

- Visualización de Segmentos:

  A diferencia de PCA, t-SNE es una técnica no lineal. Es buena para "desenredar" datos complejos y agrupar visualmente a los clientes que tienen comportamientos muy similares en pequeños cúmulos o nubes de puntos.

- Relaciones Locales:

  Mientras PCA mira el panorama general, t-SNE se enfoca en que los vecinos cercanos en el dataset original sigan estando cerca en el gráfico 2D. Esto es vital para identificar "nichos" de clientes minoristas que PCA podría pasar por alto.

Conclusión de la Elección

Para este problema de "Retail Insights S.A.", la técnica que conviene más para la toma de decisiones visual es t-SNE, ya que permite a los departamentos de marketing ver claramente la separación de los grupos. Sin embargo, para alimentar los algoritmos de clusterización y asegurar la escalabilidad del modelo, PCA es técnicamente superior debido a su menor costo computacional y su capacidad de manejar nuevos datos de forma lineal. Pero para efectos del trabajo realizaremos ambas y podremos comparar los resultados considerando la base de datos sugerida.

Lección 5

Informe Final: Segmentador Inteligente de Clientes Minoristas

Cliente: Departamento de Inteligencia de Negocios de "Retail Insights S.A."
Fecha: 12 de abril de 2026
Responsable: Reinaldo Elgueta Ábalos.

---

1. Introducción y Metodología

El presente proyecto desarrolla un sistema de segmentación de clientes utilizando técnicas de aprendizaje no supervisado. El objetivo principal es identificar patrones de comportamiento ocultos para personalizar estrategias de marketing. La metodología consistió en:

- **Limpieza de Datos:** Gestión de valores nulos mediante imputación por mediana y filtrado de valores atípicos (outliers) para asegurar la integridad estadística.
- **Preprocesamiento:** Aplicación de `StandardScaler` para normalizar las escalas de las variables (Edad, Ingresos, Gasto).
- **Reducción de Dimensionalidad:** Implementación de PCA y t-SNE para optimizar el rendimiento de los algoritmos y facilitar la visualización de los grupos.

2. Comparación de las Segmentaciones Generadas

Para garantizar la robustez de los hallazgos, se evaluaron y contrastaron tres técnicas de clusterización:

1. **K-Means:** Seleccionado como el modelo principal por su capacidad de generar particiones claras y equilibradas.
2. **Agrupamiento Jerárquico:** Utilizado para validar la estructura natural de los datos a través de dendrogramas, confirmando la existencia de 5 macro-segmentos.
3. **DBSCAN:** Empleado para la detección de anomalías y ruido, permitiendo que la segmentación final se concentre en comportamientos representativos y escalables.

3. Evaluación de la Consistencia de los Resultados

La estabilidad de la segmentación en 5 clústeres se fundamenta en evidencias matemáticas y visuales:

- **Método del Codo (Elbow Method):** La inercia del modelo mostró una reducción drástica hasta k=5, donde la pendiente se estabiliza, indicando el número óptimo de grupos.
- **Coeficiente de Silueta:** El pico máximo de cohesión y separación se alcanzó en k=5 (aprox. 0.197), validando la calidad de la agrupación.
- **Consistencia Visual:** Las proyecciones de t-SNE muestran una separación física evidente entre los grupos, sin solapamientos significativos, lo que garantiza que los segmentos son distinguibles y accionables.

Primeras gráficas obtenidas.

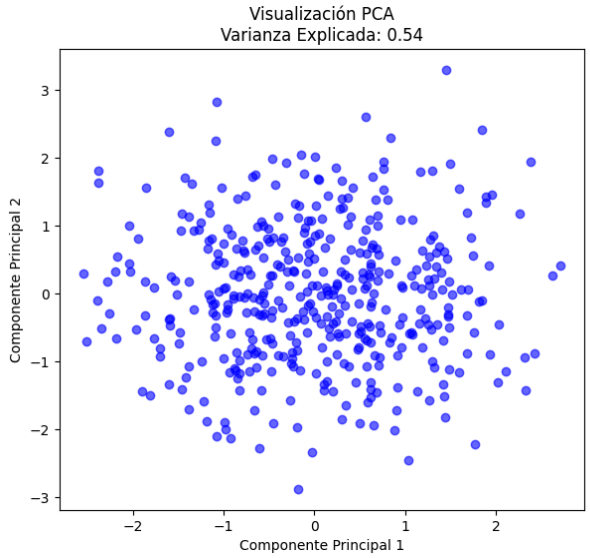

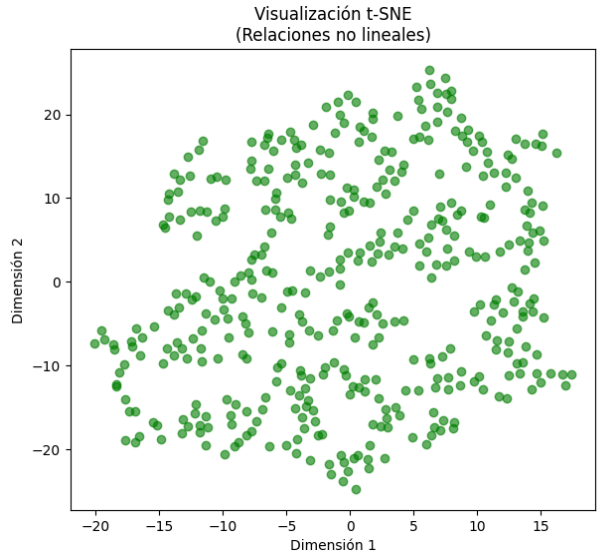

Segundas gráficas obtenidas (método del codo y silueta)

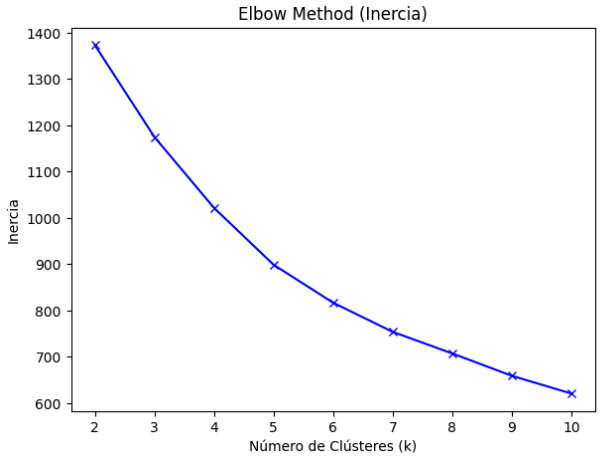

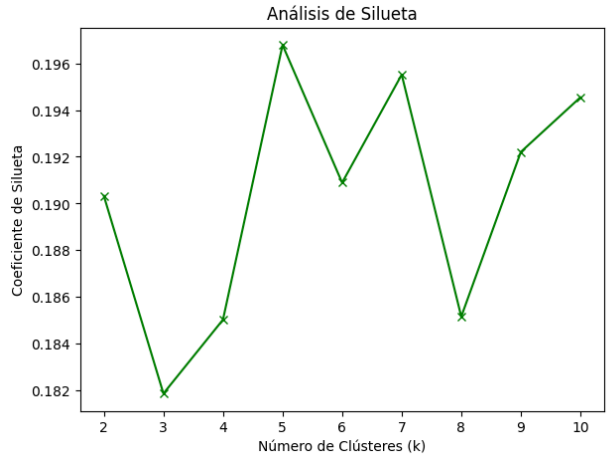

4. Visualizaciones de Impacto

El análisis se apoyó en las siguientes representaciones gráficas:

- **Comparativa PCA vs. t-SNE:** Justifica el uso de transformaciones no lineales para la interpretación de nichos de mercado.
- **Gráficos de Evaluación:** Inercia y Silueta como respaldo técnico del número de clústeres.
- **Mapa de Segmentación Final:** Proyección 2D que permite al equipo de marketing visualizar la distribución de la cartera de clientes.

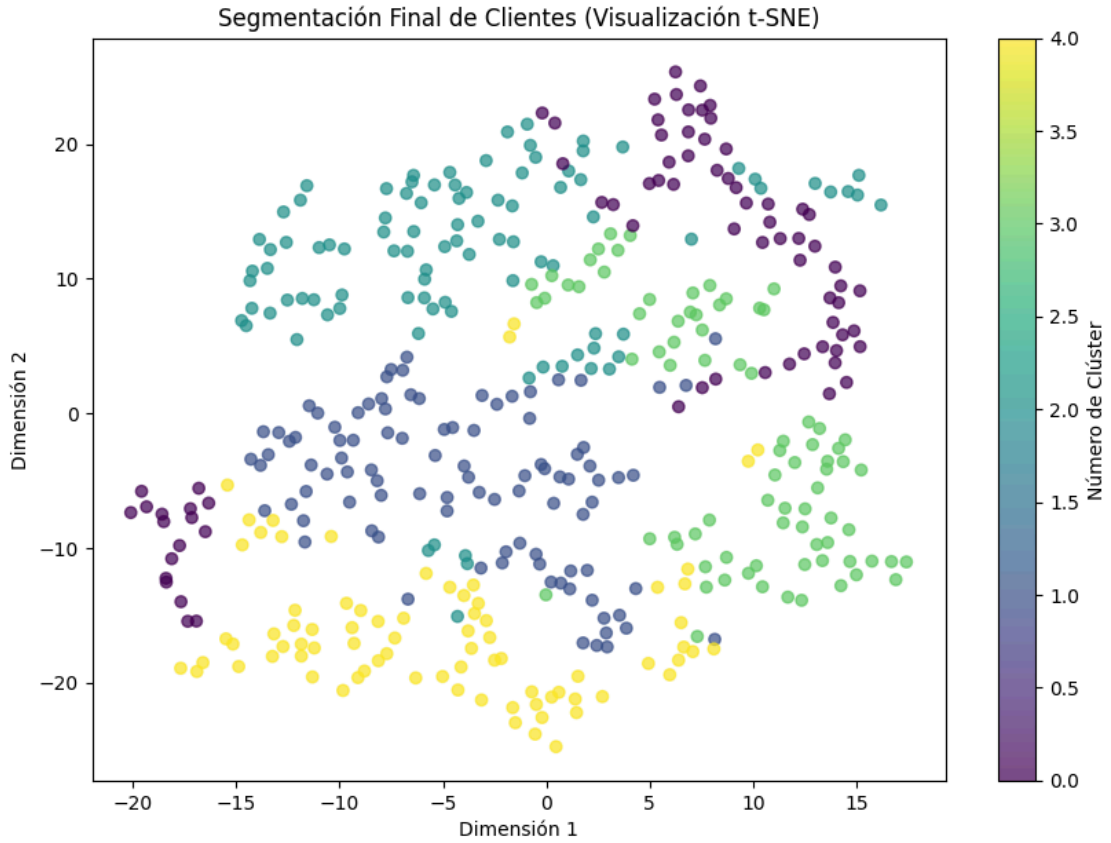

5. Sugerencias de Usos Comerciales para los Segmentos

A partir de los 5 clústeres identificados, se proponen las siguientes aplicaciones estratégicas:

- **Segmento VIP (Clúster 4):** Foco en retención exclusiva y programas de lealtad premium.
- **Segmento de Alta Frecuencia (Clúster 0):** Campañas de venta cruzada (cross-selling) para maximizar el valor de vida del cliente (LTV).
- **Segmento Ocasional (Clúster 1):** Estrategias de reactivación mediante incentivos personalizados.

- **Segmento Estable (Clúster 3):** Programas de reposición automática y comunicación de mantenimiento.
- **Segmento de Riesgo (Clúster 2):** Análisis de satisfacción para prevenir el abandono de marca.

6. Conclusión

El sistema implementado no solo resuelve la necesidad actual de segmentación, sino que es escalable para nuevos datos. La combinación de limpieza rigurosa, reducción dimensional técnica y validación métrica entrega a "Retail Insights S.A." una herramienta poderosa para la toma de decisiones basada en datos.